

SmartEye

“Clasificación de Imágenes Médicas para Detección de Cáncer de Mama mediante Aprendizaje Profundo con ResNet50, Mejora de Contraste CLAHE e Integración Multimodal de Características Auxiliares”.

Análisis de metodología, experimentos, resultados, limitaciones y líneas de mejora

1. Resumen ejecutivo	3
2. Objetivo y alcance	3
3. Datos y características del dataset	3
4. Pipeline de procesamiento	4
4.1 Preprocesamiento	4
4.2 CLAHE	4
5. Arquitectura del modelo	4
6. Diseño experimental	5
7. Resultados	6
7.1 Análisis comparativo de los modelos	6
8. Análisis crítico	7
8.1 Fortalezas	7
8.2 Limitaciones identificadas	7
8.3 Observación sobre el uso de ImageNet	8
9. Conclusiones	8

1. Resumen ejecutivo

El trabajo analiza la clasificación automática de imágenes ecográficas de mama mediante aprendizaje profundo, utilizando ResNet50 como extractor de características visuales y evaluando tres estrategias de adaptación: ajuste fino (fine tuning), mejora de contraste mediante CLAHE e integración de variables auxiliares mediante un enfoque multimodal.

El resultado central reportado es que la configuración ResNet50 + CLAHE obtiene el mejor desempeño entre las alternativas evaluadas, con 72,0 % de accuracy y 66,2 % de recall. El modelo base alcanza 66,2 % de accuracy, mientras que fine tuning alcanza 60,0 % y el modelo multimodal 61,2 %. El trabajo concluye que, bajo la configuración experimental utilizada, la mejora de la representación visual mediante CLAHE aporta más beneficio que las otras estrategias evaluadas.

2. Objetivo y alcance

El objetivo del trabajo es evaluar estrategias de aprendizaje profundo para clasificar imágenes ecográficas de mama en tres categorías: normal, benigno y maligno. El estudio busca determinar el impacto de diferentes configuraciones de ResNet50, técnicas de preprocesamiento y características auxiliares sobre el desempeño de clasificación.

- Establecer una línea base utilizando ResNet50 preentrenada con ImageNet.
- Evaluar el efecto del fine tuning sobre el backbone convolucional.
- Analizar el impacto de CLAHE como técnica de mejora de contraste.
- Evaluar una arquitectura multimodal que combine características visuales con información auxiliar.
- Comparar el desempeño de las configuraciones mediante loss, accuracy, precision y recall.

Como línea de contraste respecto de la arquitectura ResNet50, se propone incorporar un modelo **Vision Transformer (ViT) Base/16**, utilizando imágenes de entrada redimensionadas a 224×224 píxeles. Esta incorporación permitirá evaluar el desempeño de una arquitectura basada en Transformers frente al enfoque convolucional utilizado con ResNet50, manteniendo una resolución de entrada equivalente y condiciones experimentales comparables.

El objetivo no se basa solo en comparar métricas de clasificación, sino también analizar si una arquitectura basada en mecanismos de atención puede capturar representaciones discriminatorias de las imágenes ecográficas de mama de manera diferente a una CNN profunda como ResNet50.

3. Datos y características del dataset

El dataset utilizado contiene imágenes ecográficas de mama recopiladas en 2018, correspondientes a 600 pacientes femeninas de entre 25 y 75 años. Se reportan 780 imágenes PNG, con una resolución promedio de 500×500 píxeles.

Clase	Cantidad	Proporción aproximada
Normal	133	17,1 %
Benigno	437	56,0 %
Maligno	205	26,3 %

El conjunto presenta además un desbalance relevante: la clase benigna constituye aproximadamente la mitad de las imágenes, mientras que la clase normal es considerablemente menor. En un problema médico multicategoría, este desbalance puede afectar especialmente las métricas agregadas y la capacidad de detectar correctamente las clases minoritarias.

4. Pipeline de procesamiento

El pipeline puede resumirse como:

Dataset → preprocesamiento → redimensionamiento → conversión grayscale/RGB → ResNet50 → Global Average Pooling → características auxiliares (cuando corresponde) → concatenación → capas densas → Softmax.

4.1 Preprocesamiento

- Imágenes originalmente en escala de grises.
- Redimensionamiento a 224×224 píxeles.
- Conversión de un canal a tres canales RGB para mantener compatibilidad con los pesos preentrenados de ResNet50.
- Aplicación opcional de CLAHE para incrementar el contraste local.
- Normalización de las imágenes antes del ingreso al modelo.

4.2 CLAHE

CLAHE (Contrast Limited Adaptive Histogram Equalization) se utiliza para mejorar el contraste local y resaltar estructuras que pueden ser difíciles de distinguir en imágenes ecográficas de bajo contraste. El trabajo atribuye parte de la mejora del modelo a una representación visual más favorable para la extracción de características.

5. Arquitectura del modelo

La arquitectura principal utiliza ResNet50 preentrenada con ImageNet, sin su capa de clasificación final (include_top=False). La red funciona como extractor de características visuales a partir de las imágenes de entrada de 224×224 píxeles. La salida convolucional se resume mediante una capa de Global Average Pooling, obteniendo un vector compacto de características que posteriormente es utilizado por las capas finales de clasificación.

Como línea de contraste arquitectónico, se incorpora además un modelo Vision Transformer (ViT-Base/16), utilizando la misma resolución de entrada de 224×224 píxeles. Esta arquitectura permite comparar el enfoque basado en redes convolucionales de ResNet50 con una arquitectura

basada en mecanismos de atención, manteniendo condiciones de entrada equivalentes. Como ya se mencionó en la sección 2, el objetivo es analizar si las representaciones visuales obtenidas mediante un Transformer permiten mejorar o complementar el desempeño alcanzado por la arquitectura convolucional.

En la variante multimodal, las variables auxiliares provenientes de un archivo CSV son procesadas mediante capas densas independientes. Las representaciones visuales y auxiliares se concatenan y se utilizan como entrada de las capas finales de clasificación.

Para ambas arquitecturas, la salida final consiste en una capa Softmax de tres neuronas, correspondiente a las clases benigno, maligno y normal. La comparación entre ResNet50 y ViT-Base/16 se plantea bajo condiciones experimentales equivalentes, utilizando la misma resolución de entrada, partición de datos y métricas de evaluación, con el objetivo de atribuir las diferencias de desempeño principalmente a las características propias de cada arquitectura.

6. Diseño experimental

Se evalúan las siguientes configuraciones principales:

Configuración	Descripción	Propósito
ResNet50 Base	Backbone preentrenado utilizado como extractor.	Establecer línea base.
ResNet50 + Fine Tuning	Actualización parcial de pesos convolucionales con learning rate reducido.	Adaptar características al dominio médico.
ResNet50 + CLAHE	Aplicación de mejora de contraste antes de la extracción.	Mejorar la representación visual.
ResNet50 Multimodal	Características visuales + variables auxiliares.	Evaluar información contextual adicional.
Vit -Base/16		Evaluar un contraste con el modelo Resnet50.
Vit -Base/16 + CLAHE		Evaluar si hay una mejora en las metricas aplicando CLAHE

7. Resultados

La tabla experimental es la siguiente:

Modelo	Loss	Accuracy	Precision	Recall
ResNet50 Base	0,860	0,662	0,716	0,474
ResNet50 + Fine Tuning	0,844	0,600	0,776	0,429
ResNet50 + CLAHE	0,850	0,720	0,625	0,662
ResNet50 Multimodal	0,864	0,612	0,690	0,474
Vit-Base/16		0.8	0.776	0.774
Vit-Base/16 + CLAHE		0.63	0.39	0.38

7.1 Análisis comparativo de los modelos

Los resultados obtenidos muestran diferencias importantes entre las arquitecturas y estrategias de preprocesamiento evaluadas. En el caso de **ResNet50**, la configuración base alcanza una accuracy de 66,2%, con una precision de 71,6% y un recall de 47,4%. Este comportamiento indica que, si bien el modelo presenta una capacidad razonable para realizar predicciones precisas, su bajo recall evidencia dificultades para identificar correctamente una proporción significativa de los casos pertenecientes a las clases evaluadas.

La aplicación de **Fine Tuning** sobre ResNet50 produce una reducción de la accuracy hasta el 60,0% y del recall hasta el 42,9%, aunque incrementa la precision hasta el 77,6%. Esto indica que el ajuste de las capas de la red hizo al modelo más selectivo en sus predicciones, reduciendo la cantidad de falsos positivos, pero a costa de una menor capacidad para recuperar correctamente los casos positivos. Por lo tanto, bajo las condiciones experimentales utilizadas, el Fine Tuning no produjo una mejora global del modelo.

La configuración **ResNet50 + CLAHE** presenta el mejor comportamiento entre las variantes de ResNet50. La accuracy aumenta hasta el 72,0% y el recall alcanza el 66,2%, lo que representa una mejora considerable respecto del modelo base, especialmente en la capacidad de identificación de las clases. Sin embargo, la precision disminuye hasta el 62,5%. Este resultado sugiere que la mejora del contraste mediante CLAHE favorece la extracción de características relevantes para la discriminación de las imágenes, aunque genera un incremento de predicciones incorrectas entre los casos identificados como positivos. En términos globales, esta configuración presenta el mejor equilibrio entre las métricas de ResNet50 evaluadas.

Por otra parte, la configuración **ResNet50 Multimodal** alcanza una accuracy de 61,2%, una precision de 69,0% y un recall de 47,4%. Estos resultados no superan a la configuración visual con CLAHE, lo que indica que la incorporación de las variables auxiliares utilizadas en el experimento no produjo una mejora significativa del desempeño.

El comportamiento del **ViT-Base/16 sin CLAHE** resulta destacable. Durante el entrenamiento, el modelo alcanza una accuracy cercana al 97–99% y un loss aproximado de 0,05, mostrando una elevada capacidad para ajustar los datos de entrenamiento. Sin embargo, esta elevada performance no se mantiene completamente sobre el conjunto de evaluación, donde alcanza una accuracy del 80,0%, una precisión macro del 77,6% y un recall macro del 77,4%. La diferencia entre el desempeño de entrenamiento y evaluación evidencia un **sobreajuste significativo**.

Finalmente, la incorporación de **CLAHE al ViT-Base/16** produce un deterioro del desempeño. La accuracy disminuye hasta aproximadamente 62,5%, mientras que la precisión y el recall se reducen a valores cercanos al 39% y 42%, respectivamente. Este comportamiento contrasta con lo observado en ResNet50, donde CLAHE produjo una mejora. Esto sugiere que el efecto del preprocesamiento no es independiente de la arquitectura utilizada: mientras ResNet50 parece beneficiarse de la mejora de contraste, ViT-Base/16 obtiene mejores resultados utilizando las imágenes sin CLAHE.

En conjunto, los resultados indican que **ViT-Base/16 sin CLAHE presenta el mayor desempeño sobre el conjunto de evaluación**, alcanzando una accuracy del 80,0%, pero también presenta el mayor indicio de sobreajuste. Por su parte, **ResNet50 + CLAHE alcanza una accuracy menor (72,0%), pero muestra un comportamiento más estable dentro de las variantes ResNet50 evaluadas y un recall considerablemente superior al de las configuraciones ResNet50 Base**.

Los resultados sugieren que ViT posee un potencial de clasificación elevado, pero requiere estrategias adicionales de regularización y control del sobreajuste para verificar si su superioridad en accuracy puede mantenerse frente a datos no vistos. En cambio, ResNet50 + CLAHE constituye una alternativa más equilibrada dentro de las configuraciones evaluadas y evidencia la importancia de adaptar el preprocesamiento a la arquitectura utilizada.

8. Análisis crítico

8.1 Fortalezas

- Utilización de transferencia de aprendizaje mediante ResNet50.
- Comparación de diferentes estrategias de adaptación del modelo.
- Incorporación de una técnica específica de mejora de contraste.
- Exploración de una arquitectura multimodal.
- Comparación mediante múltiples métricas en lugar de accuracy únicamente.
- Identificación explícita de limitaciones y líneas de trabajo futuro.

8.2 Limitaciones identificadas

- Tamaño reducido del conjunto de datos.
- Desbalance entre clases.
- Uso de una única partición Hold-Out 70/15/15, lo que puede hacer que los resultados dependan de la división elegida.
- Variabilidad observada en validación y evidencia de sobreajuste.

8.3 Observación sobre el uso de ImageNet

Se señala como línea futura la utilización de modelos preentrenados en dominios biomédicos. Esta propuesta es coherente con la diferencia entre imágenes naturales de ImageNet y estudios médicos. En esta etapa no se presenta una comparación experimental con un backbone preentrenado específicamente en imágenes médicas, por lo que el beneficio potencial de esa estrategia queda planteado como hipótesis futura.

9. Conclusiones

El estudio establece una base experimental para la clasificación de imágenes ecográficas de mama mediante aprendizaje profundo. Entre las configuraciones evaluadas, ResNet50 + CLAHE obtiene el mejor desempeño global reportado dentro de las variantes de ResNet50, con 72,0 % de accuracy y 66,2 % de recall.

El resultado más relevante es que la mejora de contraste parece aportar un beneficio concreto en un conjunto caracterizado por imágenes oscuras y de bajo contraste. En cambio, el fine tuning incrementa la precisión, pero reduce el accuracy y el recall, mientras que la estrategia multimodal no supera al modelo basado únicamente en imágenes.

Por otro lado, ViT-Base/16 sin CLAHE alcanzó una accuracy del 80,0 %, mostrando un resultado superior al obtenido por las configuraciones de ResNet50 evaluadas. Sin embargo, la diferencia entre su desempeño durante el entrenamiento y la evaluación evidencia un importante riesgo de **sobreajuste**, por lo que este resultado debe interpretarse considerando su capacidad de generalización. En contraste, la incorporación de CLAHE al ViT produjo una disminución considerable del rendimiento, alcanzando una accuracy del 62,5 %, lo que indica que el efecto del preprocesamiento depende de la arquitectura empleada.

La principal conclusión para el desarrollo futuro es que el rendimiento observado todavía debe considerarse experimental. El tamaño y desbalance del dataset, la utilización de una única partición Hold-Out, las fluctuaciones observadas durante la validación y la ausencia de una evaluación externa limitan la capacidad de generalizar los resultados. Por ello, el siguiente paso debería centrarse tanto en robustecer la evaluación como en mejorar la representación visual y la estrategia de entrenamiento.

El trabajo constituye, por lo tanto, un punto de partida adecuado para evolucionar hacia un sistema de clasificación más robusto, mediante una evaluación más rigurosa y el desarrollo de estrategias capaces de mejorar la generalización de los modelos.